Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

Отчёт по рубежному контролю №2

По дисциплине:
«Технологии машинного обучения»

Выполнил:

Студент группы ИУ5 _____ **Забелина В.А.**

(Подпись, дата) (Фамилия И.О.)

Проверил:

_____ **Гапанюк Ю. Е.**

(Подпись, дата) (Фамилия И.О.)

Москва, 2021

Вариант №9

Задание

Задание. Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Набор данных

https://www.kaggle.com/rubenssjr/brasilian-houses-to-rent

Решение

Импорт библиотек

Ввод [37]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from pandas.plotting import scatter_matrix
import warnings
warnings.filterwarnings('ignore')
sns.set(style="ticks")
%matplotlib inline
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
```

Ввод [182]:
```
data = pd.read_csv('houses_to_rent.csv')
```

Ввод [183]:
```
data.head()
```

Out[183]:

	Unnamed: 0	city	area	rooms	bathroom	parking spaces	floor	animal	furniture	hoa	rent amount	property tax	fire insurance	total
0	0	1	240	3	3	4	-	acept	furnished	R$0	R$8,000	R$1,000	R$121	R$9,121
1	1	0	64	2	1	1	10	acept	not furnished	R$540	R$820	R$122	R$11	R$1,493
2	2	1	443	5	5	4	3	acept	furnished	R$4,172	R$7,000	R$1,417	R$89	R$12,680
3	3	1	73	2	2	1	12	acept	not furnished	R$700	R$1,250	R$150	R$16	R$2,116
4	4	1	19	1	1	0	-	not acept	not furnished	R$0	R$1,200	R$41	R$16	R$1,257

Ввод [184]:
```
parts = np.split(data, [14], axis=1)
data = parts[0]
```

Ввод [185]:
```
data.dtypes
```

Out[185]:
```
Unnamed: 0        object
city              object
area              object
rooms             object
bathroom          object
parking spaces    object
floor             object
animal            object
furniture         object
hoa               object
rent amount       object
property tax      object
fire insurance    object
total             object
dtype: object
```

Ввод [186]:
```
data.drop(['city','Unnamed: 0', 'furniture'], axis = 1, inplace = True)
```

Ввод [187]:
```
le = LabelEncoder()
le.fit(data.animal)
data.animal = le.transform(data.animal)
```

Ввод [188]:
```
data['area'] = data['area'].apply(pd.to_numeric, errors='coerce')
data['rooms'] = data['rooms'].apply(pd.to_numeric, errors='coerce')
data['bathroom'] = data['bathroom'].apply(pd.to_numeric, errors='coerce')
data['parking spaces'] = data['parking spaces'].apply(pd.to_numeric, errors='coerce')
data['floor'] = data['floor'].replace('-', 0)
data['floor'] = data['floor'].apply(pd.to_numeric, errors='coerce')
data['floor'] = data['floor'].replace(0,np.nan)
data['floor'] = data['floor'].fillna(data['floor'].mean())
data['rent amount'] = data['rent amount'].str[2:].replace('\,', '', regex=True)
data['rent amount'] = data['rent amount'].apply(pd.to_numeric, errors='coerce')

data['hoa'] = data['hoa'].str[2:].replace('\,', '', regex=True)
data['hoa'] = data['hoa'].apply(pd.to_numeric, errors='coerce')
data['hoa'] = data['hoa'].replace(0,np.nan)
data['hoa'] = data['hoa'].fillna(data['floor'].mean())

data['property tax'] = data['property tax'].str[2:].replace('\,', '', regex=True)
data['property tax'] = data['property tax'].apply(pd.to_numeric, errors='coerce')
data['property tax'] = data['property tax'].replace(0,np.nan)
data['property tax'] = data['property tax'].fillna(data['floor'].mean())

data['fire insurance'] = data['fire insurance'].str[2:].replace('\,', '', regex=True)
data['fire insurance'] = data['fire insurance'].apply(pd.to_numeric, errors='coerce')

data['total'] = data['total'].str[2:].replace('\,', '', regex=True)
data['total'] = data['total'].apply(pd.to_numeric, errors='coerce')
```

Ввод [189]:
```
data.isnull().sum()
# проверим есть ли пропущенные значения
```

Out[189]:
```
area              0
rooms             0
bathroom          0
parking spaces    0
floor             0
animal            0
hoa               0
rent amount       0
property tax      0
fire insurance    0
total             0
dtype: int64
```

Ввод [190]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6080 entries, 0 to 6079
Data columns (total 11 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   area            6080 non-null   int64
 1   rooms           6080 non-null   int64
 2   bathroom        6080 non-null   int64
 3   parking spaces  6080 non-null   int64
 4   floor           6080 non-null   float64
 5   animal          6080 non-null   int32
 6   hoa             6080 non-null   float64
 7   rent amount     6080 non-null   int64
 8   property tax    6080 non-null   float64
 9   fire insurance  6080 non-null   int64
 10  total           6080 non-null   int64
dtypes: float64(3), int32(1), int64(7)
memory usage: 498.8 KB
```

Ввод [191]:
```
data.head()
```

Out[191]:

	area	rooms	bathroom	parking spaces	floor	animal	hoa	rent amount	property tax	fire insurance	total
0	240	3	3	4	7.621436	0	7.621436	8000	1000.0	121	9121
1	64	2	1	1	10.000000	0	540.000000	820	122.0	11	1493
2	443	5	5	4	3.000000	0	4172.000000	7000	1417.0	89	12680
3	73	2	2	1	12.000000	0	700.000000	1250	150.0	16	2116
4	19	1	1	0	7.621436	1	7.621436	1200	41.0	16	1257

Ввод [192]:
```
#Построим корреляционную матрицу
fig, ax = plt.subplots(figsize=(15,7))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

Out[192]: <AxesSubplot:>

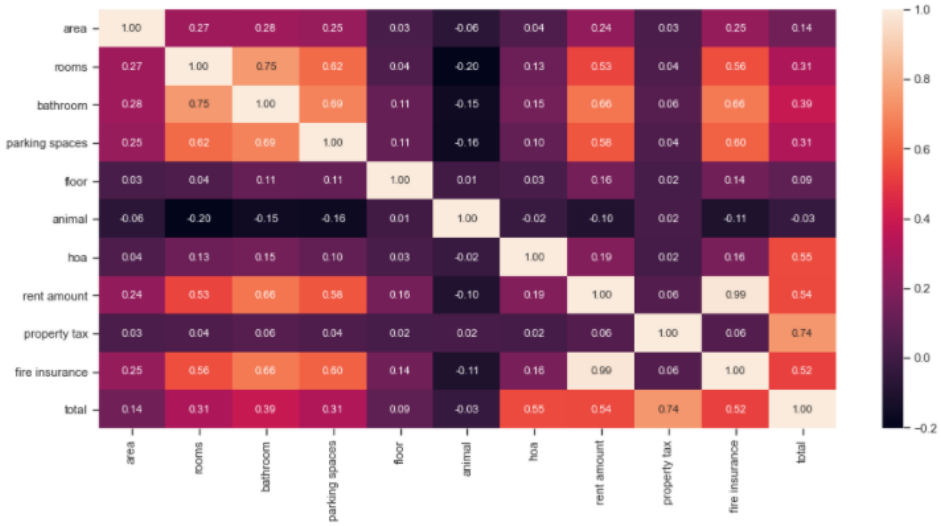

Ввод [193]:
```
X = data.drop(['total'], axis = 1)
Y = data.total
print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', Y.head())
```

```
Входные данные:

    area  rooms  bathroom  parking spaces      floor  animal          hoa  \
0   240      3         3               4   7.621436       0     7.621436
1    64      2         1               1  10.000000       0   540.000000
2   443      5         5               4   3.000000       0  4172.000000
3    73      2         2               1  12.000000       0   700.000000
4    19      1         1               0   7.621436       1     7.621436

   rent amount  property tax  fire insurance
0         8000        1000.0             121
1          820         122.0              11
2         7000        1417.0              89
3         1250         150.0              16
4         1200          41.0              16

Выходные данные:
```

Выходные данные:

```
 0     9121
1     1493
2    12680
3     2116
4     1257
Name: total, dtype: int64
```

Ввод [194]:

```
X_train,  X_test,  Y_train,  Y_test = train_test_split(X,  Y, random_state = 0, test_size = 0.1)
print('Входные параметры обучающей выборки:\n\n',X_train.head(), \
      '\n\nВходные параметры тестовой выборки:\n\n', X_test.head(), \
      '\n\nВыходные параметры обучающей выборки:\n\n', Y_train.head(), \
      '\n\nВыходные параметры тестовой выборки:\n\n', Y_test.head())
```

Входные параметры обучающей выборки:

```
       area  rooms  bathroom  parking spaces  floor  animal    hoa  \
6065   133      2         2               1    7.0       0  813.0
2207    44      1         1               1    6.0       1  571.0
1277    85      2         1               0    4.0       0  620.0
3847    79      3         2               2    3.0       0  995.0
1299    52      2         1               1    8.0       0  760.0

      rent amount  property tax  fire insurance
6065         2713    160.000000              35
2207         2000    130.000000              26
1277         2190      7.621436              28
3847         2200    146.000000              28
1299         3000    145.000000              39
```

Входные параметры тестовой выборки:

```
       area  rooms  bathroom  parking spaces     floor  animal          hoa  \
1430    19      1         1               0  7.621436       1     7.621436
3875    54      2         1               1  3.000000       0   286.000000
5399   124      3         1               0  8.000000       1  1200.000000
394     55      2         2               1  9.000000       0   337.000000
2179    70      2         2               1  1.000000       0   280.000000

      rent amount  property tax  fire insurance
1430         1200          41.0              16
3875         1099          23.0              14
5399         1200          84.0              16
394          2500          86.0              32
2179         1000         138.0              13
```

Выходные параметры обучающей выборки:

```
 6065    3721
2207    2727
1277    2838
3847    3369
1299    3944
Name: total, dtype: int64
```

```
1277    2656
3847    3369
1299    3944
Name: total, dtype: int64

Выходные параметры тестовой выборки:

 1430    1257
3875    1422
5399    2500
394     2955
2179    1431
Name: total, dtype: int64
```

Ввод [195]:
```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error,  median_absolute_error, r2_score
```

Ввод [196]:
```
Lin_Reg = LinearRegression().fit(X_train, Y_train)

lr_y_pred = Lin_Reg.predict(X_test)
print('Средняя абсолютная ошибка:',   mean_absolute_error(Y_test, lr_y_pred))
print('Средняя квадратичная ошибка:', mean_squared_error(Y_test, lr_y_pred))
print('Median absolute error:',       median_absolute_error(Y_test, lr_y_pred))
print('Коэффициент детерминации:',    r2_score(Y_test, lr_y_pred))
```

```
Средняя абсолютная ошибка: 4.587720001131204
Средняя квадратичная ошибка: 290.2656894440338
Median absolute error: 3.1786169657086703
Коэффициент детерминации: 0.9999856427207927
```

Ввод [204]:
```
plt.scatter(X_test.hoa, Y_test,    marker = 's', label = 'Тестовая выборка')
plt.scatter(X_test.hoa, lr_y_pred, marker = '.', label = 'Предсказанные данные')
plt.legend (loc = 'lower right')
plt.xlabel ('Hoa')
plt.ylabel ('Total')
plt.show()
```

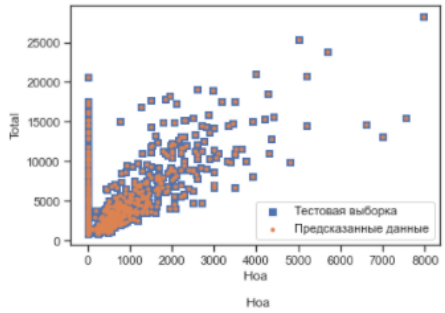

Hoa

Ввод [205]:
```
from sklearn.ensemble import RandomForestRegressor
```

Ввод [206]:
```
forest_1 = RandomForestRegressor(n_estimators=5, oob_score=True, random_state=10)
forest_1.fit(X, Y)
```

Out[206]:
```
RandomForestRegressor(n_estimators=5, oob_score=True, random_state=10)
```

Ввод [207]:
```
Y_predict = forest_1.predict(X_test)
print('Средняя абсолютная ошибка:',   mean_absolute_error(Y_test, Y_predict))
print('Средняя квадратичная ошибка:', mean_squared_error(Y_test, Y_predict))
print('Median absolute error:',       median_absolute_error(Y_test, Y_predict))
print('Коэффициент детерминации:',    r2_score(Y_test, Y_predict))
```

```
Средняя абсолютная ошибка: 61.89769736842104
Средняя квадратичная ошибка: 60529.15072368422
Median absolute error: 17.700000000000045
Коэффициент детерминации: 0.9970060742667093
```

Ввод [208]:
```
plt.scatter(X_test.hoa, Y_test,    marker = 'o', label = 'Тестовая выборка')
plt.scatter(X_test.hoa, Y_predict, marker = '.', label = 'Предсказанные данные')
plt.legend(loc = 'lower right')
plt.xlabel('Hoa')
plt.ylabel('Total')
plt.show()
```

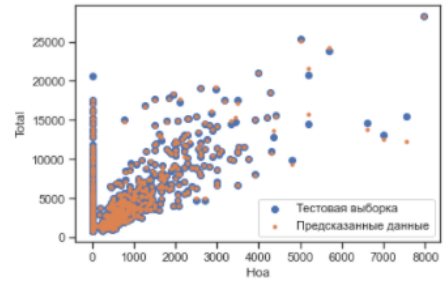

Ввод [ ]:
```
# The end.
```